

國立虎尾科技大學

資訊管理系碩士班

碩士論文

以企業會議記錄為例之結構化文件解析與
GraphRAG 檢索系統

**A Structured Document Parsing and GraphRAG
Retrieval System for Enterprise Meeting Records**

研究生：黃皓倫

指導教授：胡念祖 教授

中華民國 115 年 7 月

以企業會議記錄為例之結構化文件解析與
GraphRAG 檢索系統

A Structured Document Parsing and GraphRAG
Retrieval System for Enterprise Meeting Records

研 究 生：黃皓倫
指 導 教 授：胡念祖 教授

Student：Hao-Lun Huang
Advisor：Prof. Nian-Ze Hu

國立虎尾科技大學
資訊管理系碩士班
碩士論文

A Thesis Submitted to Department of Information Management
College of Management
National Formosa University
in Partial Fulfillment of the Requirements
for the Degree of Master of Science
in
Information Management

July, 2026
Huwei, Yunlin, Taiwan (R.O.C.)

中 華 民 國 115 年 7 月

以企業會議記錄為例之結構化文件解析與 GraphRAG 檢索系統

學生：黃皓倫

指導教授：胡念祖 教授

國立虎尾科技大學資訊管理系碩士班

摘要

企業內部會議記錄著專案決策、責任分派、產品開發進度、測試要求與追蹤結果等資訊，實務上卻常以 PDF 或掃描型文件分散保存。這些文件並非完全非結構化文本；以本研究所觀察之去識別化樣本而言，會議主檔與會議項目多具有穩定欄位，包含會議名稱、日期、權責單位、出席人員、負責人、預計日期與追蹤結果等資料。然而，既有關鍵字檢索多停留在「找出含有查詢詞的文件」層次，難以回答關鍵字落在哪個欄位、對應哪一項任務、由誰負責、時程如何安排，以及該議題與其他文件或關鍵詞之間是否存在關聯。

針對上述限制，本研究建構一套面向企業會議記錄的結構感知檢索、知識圖譜關聯展開與 GraphRAG 問答系統。系統先解析固定格式會議記錄 PDF，擷取會議名稱、會議日期、地點、主席、記錄人、權責單位、出席人員，並將項次、會議內容、負責人、預計日期、實際完成日與追蹤結果整理為會議項目層級資料。接著，系統依據欄位命中、欄位權重、任務狀態與文件相關度分數排序檢索結果；使用者選定結果後，再以文件、會議項目或命中關鍵字作為 Neo4j 圖譜查詢起點，展開其與人員、任務、日期、產品與其他關鍵詞之間的關係。

最後，系統結合 Qdrant 向量檢索與 Ollama 本地語言模型，將結構化檢索結果與圖譜脈絡轉換為可回溯來源的 GraphRAG 回答。研究重點不在建立通用文件理解模型，而在驗證固定格式會議記錄經由結構解析、圖譜化與檢索增強生成後，能否提升企業知識查詢的可解釋性與可追溯性。

關鍵詞：文件結構解析、知識圖譜、GraphRAG、向量檢索

A Structured Document Parsing and GraphRAG Retrieval System for Enterprise Meeting Records

Student : Hao-Lun Huang

Advisor : Prof. Nian-Ze Hu

Department of Information Management
National Formosa University

Abstract

Enterprise meeting records preserve project decisions, responsibility assignments, product-development progress, testing requirements, and follow-up results. In practice, however, these records are often stored as PDF files or scanned documents, which makes them difficult to search beyond simple keyword matching. The meeting records examined in this study are not unstructured long-form texts; rather, they contain stable fields such as meeting name, date, responsible unit, attendees, owners, planned dates, completion dates, and tracking results. Conventional full-text retrieval can identify documents containing a query term, but it seldom explains where the term appears, which action item it relates to, who is responsible for it, or how it connects to other records and keywords.

To address this gap, this study develops a structured document parsing and GraphRAG retrieval system for enterprise meeting records. The system first parses fixed-format meeting-record PDFs and extracts meeting-level metadata and item-level fields, including item number, discussion content, owner, planned date, actual completion date, and tracking result. It then ranks results by combining field-level matches, field weights, task-status signals, and document-level relevance. After a user selects a result, the selected document, meeting item, or matched keyword becomes the starting point for graph traversal in Neo4j, where related people, tasks, dates, products, and keywords are expanded.

Finally, the system integrates Qdrant-based vector retrieval with a local language model through Ollama, allowing structured retrieval results and graph context to be transformed into source-grounded GraphRAG answers. The contribution of this study is not a general-purpose document understanding model; instead, it demonstrates how fixed-format enterprise meeting records can be converted into searchable, explainable, and traceable organizational knowledge resources.

Keywords: Document Structure Parsing 、 Knowledge Graph 、 GraphRAG 、
Vector Retrieval

目錄

摘要	i
目錄	iii
第一章 緒論	1
1.1 研究背景	1
1.2 研究動機	1
1.3 研究目的	2
1.4 研究流程	3
第二章 文獻探討	4
2.1 企業知識管理、組織記憶與企業搜尋	4
2.2 會議記錄、任務追蹤與行動項目文件	4
2.3 文件結構解析、表格辨識與欄位抽取	5
2.4 詞彙式檢索、BM25 與欄位化檢索	5
2.5 檢索粒度、向量檢索與混合式檢索	6
2.6 查詢擴展與圖譜輔助查詢擴展	6
2.7 可解釋檢索與來源可追溯性	7
2.8 知識圖譜與關聯查詢	7
2.9 RAG 與 GraphRAG	8
2.10 檢索、關聯展開與 GraphRAG 評估方法	9
第三章 研究方法	10
3.1 研究架構	10
3.2 會議記錄結構化資料模型	11
3.3 會議記錄結構化解析方法	12
3.4 結構感知檢索模型	12
3.4.1 檢索單位與欄位集合	13
3.4.2 項目層級排序分數	14
3.4.3 文件層級結果彙整	15
3.5 知識圖譜建構方法	15
3.6 圖譜關聯展開與圖譜輔助查詢擴展	17
3.7 GraphRAG 問答方法	19
參考文獻	22

第一章 緒論

1.1 研究背景

企業在日常營運、專案管理、產品開發、測試驗證、設計審查及跨部門協調中，會反覆產生會議記錄。這些文件表面上屬於行政紀錄，實際上卻累積了決策理由、待解問題、任務分派、責任歸屬、預計完成時程與後續追蹤結果。若能被妥善保存與再利用，會議記錄可成為企業知識管理與組織記憶的一部分。

以本研究採用的去識別化企業會議記錄樣本為例，文件格式相當固定，且具有明顯半結構化特徵。會議主檔通常記載會議名稱、會議日期、地點、主席、記錄人、權責單位與出席人員；會議項目則以表格形式列出項次、會議內容、負責人、預計日期、實際完成日與追蹤結果。換言之，這類 PDF 雖以文件形式保存，內容卻不只是長篇文字，而是同時包含欄位、任務、人員、日期與狀態的管理資料。

在多數企業實務中，會議記錄仍以檔案目錄或文件管理系統保存。當使用者要查找特定議題、產品、專案、任務或人員時，常仰賴檔名、資料夾分類或全文關鍵字檢索。這種方式可以回答「哪些文件出現某個詞」，但對於更細緻的問題，例如關鍵字位於哪個欄位、對應哪一項任務、由誰負責、預計何時完成，或與哪些會議項目共同出現，便缺乏足夠支援。

基於此，本研究認為會議記錄檢索的重點不應只停留在文件層級的關鍵字比對，而應往文件內部結構與跨文件關聯延伸。也就是說，系統需要從「找出相關文件」推進到「理解欄位、任務、人員與日期之間的關係」。

相關研究也支持這樣的處理方向。Zanibbi、Blostein 與 Cordy [1] 指出，表格辨識除了文字擷取，還涉及表格模型、實體位置、邏輯結構與資料關係；LayoutLM 相關研究則顯示，文件理解需同時考慮文字與版面位置，因為空間配置往往反映欄位與語意結構 [2]。這些觀點提醒本研究：處理企業會議記錄時，若忽略欄位與表格結構，檢索與問答結果容易失去可解釋性。

在上述背景下，本研究以固定格式企業會議記錄為研究對象，設計結構感知檢索、知識圖譜關聯展開與 GraphRAG 問答流程。期望將原本靜態保存的 PDF 會議記錄，轉換為可檢索、可排序、可探索關聯，並可回溯來源的企業知識資源。

1.2 研究動機

現有會議記錄搜尋多以全文關鍵字為主。使用者輸入查詢後，系統通常依關鍵字是否出現、出現頻率或簡單相關度回傳文件。這種方式具備基本可用性，但放在企業會議記錄情境中，仍至少存在三個限制。

第一，全文檢索很容易抹平欄位差異。同一個詞出現在會議名稱、會議內容或負責人欄位時，代表的意義並不相同。出現在會議名稱中，通常表示查詢與會議主題直接相關；出現在會議項目內容中，可能指向某項任務或決議；若出現在負責人欄位，則更接近責任查詢。若只把整份文件視為一串文字，系統便難以辨識這些語意位置的差異。

第二，會議記錄中的任務與責任資訊具有高管理價值，但傳統搜尋不擅長回應任務導向問題。負責人、預計日期、實際完成日與追蹤結果等欄位，對專案追蹤與跨部

門協作十分關鍵。實務使用者往往不是只想找到一份文件，而是想確認某項工作由誰承接、是否已完成、是否設定期限，以及此任務與哪些議題相互牽連。

第三，若生成式問答系統僅依賴向量檢索取得相似片段，仍可能忽略會議記錄中的結構關係。一般 Retrieval-Augmented Generation (RAG) 可把外部文件作為語言模型生成答案的依據；然而，若檢索單位只是切割後的文字片段，任務、負責人、日期與關鍵詞之間的對應關係可能被切斷。對企業會議記錄而言，回答除了語意相近文本，也需要可追溯的欄位資訊與圖譜關聯。

查詢擴展研究指出，使用者查詢通常短而不完整，且可能與文件實際用詞存在詞彙落差，因此可透過相關詞或回饋資訊改善檢索效果 [3]。Knowledge-Aware Query Expansion 進一步指出，若將知識圖譜的結構關係納入擴展，可更好地支援同時具有文本需求與關係需求的半結構化檢索任務 [4]。這與本研究的設計相近：系統先以關鍵字進行結構化檢索，再於使用者選定結果後，透過圖譜展開文件、會議項目、人員、日期與關鍵詞關係。

綜合而言，本研究的動機在於把會議記錄檢索從「文件排名」推進至「結構理解、關聯探索與來源可驗證問答」。換句話說，系統不只要回答哪份文件可能相關，還要說明相關的理由，包括命中欄位、牽涉任務、負責人員與後續可供問答使用的脈絡。

1.3 研究目的

本研究旨在建構一套面向固定格式企業會議記錄的結構感知檢索、知識圖譜關聯展開與 GraphRAG 問答系統，使會議記錄由靜態 PDF 文件轉化為可檢索、可關聯分析且可回溯來源的企業知識資源。具體目的如下：

- 一、建立固定格式會議記錄的結構化解析方法。系統解析會議記錄 PDF 中的會議主檔與會議項目，擷取會議名稱、會議日期、地點、主席、記錄人、權責單位、出席人員、項次、會議內容、負責人、預計日期、實際完成日與追蹤結果等欄位，形成後續檢索、排序與分析所需的結構化資料。
- 二、設計結構感知檢索機制。檢索流程不只判斷查詢詞是否出現，也記錄查詢詞命中的欄位，並依欄位語意、關鍵字相關度與任務屬性調整排序，使結果具備較高的可解釋性。
- 三、建立會議記錄知識圖譜。將文件、會議、會議項目、人員、單位、日期與關鍵詞建模為節點，並以關係表示會議包含項目、項目由人員負責、項目具有預計日期與項目提及關鍵詞等事實，以支援多跳查詢與圖譜式關聯展開。
- 四、提出以檢索結果為起點的圖譜關聯展開流程。當使用者選擇某一筆檢索結果後，系統可依文件、會議項目或命中關鍵字定位圖譜起點，進一步展開相關人員、任務、日期、關鍵詞與其他會議項目，讓檢索結果從清單轉為可探索的知識網絡。
- 五、整合結構化檢索、知識圖譜與向量檢索，形成具來源回溯能力的 GraphRAG 問答流程。系統以結構化檢索結果、圖譜關聯路徑與語意相近內容作為語言模型輸入脈絡，並要求回答附帶來源資訊與圖譜路徑，以降低生成內容脫離資料來源的風險。

需要說明的是，本研究並不追求建立通用文件理解模型，而是以固定格式企業會議記錄作為明確場域，驗證結構感知檢索、知識圖譜關聯展開與 GraphRAG 問答三層

式架構的可行性。LayoutLM、DocLayNet 與 PubTabNet 等研究可作為未來擴充至多版面文件、掃描型 PDF 與表格影像辨識的參考；本研究現階段則聚焦於格式穩定且可取得文字層內容的會議記錄。

1.4 研究流程

本研究流程如圖 1.1 所示。整體研究先從企業會議記錄檢索的實務痛點出發，界定研究問題與研究範圍；接著透過文獻探討整理企業知識管理、資訊檢索、欄位化檢索、文件結構解析、查詢擴展、知識圖譜、RAG 與 GraphRAG 相關研究，作為後續系統設計的理論基礎。

在資料處理階段，本研究使用去識別化且格式固定的會議記錄樣本，將文件解析為會議主檔與會議項目兩層資料模型。隨後，系統依查詢詞與欄位命中情形執行結構感知檢索，輸出相關度分數、命中欄位與摘要片段。使用者點擊結果後，系統再以該文件、會議項目或命中關鍵字作為知識圖譜起點，展開其與人員、單位、日期及關鍵詞之間的關係。

最後，結構化檢索結果、圖譜關聯脈絡與向量檢索結果會被組合為 GraphRAG 問答上下文，由語言模型產生自然語言回答，並附帶來源資訊與圖譜路徑。後續實驗將以檢索排序品質、欄位命中正確性、關聯展開正確性與問答來源可追溯性作為主要評估面向。

圖 1.1 論文架構圖

資料來源：本研究整理

第二章 文獻探討

2.1 企業知識管理、組織記憶與企業搜尋

企業會議記錄不只是行政流程中的附屬文件；在專案執行、產品開發、設計審查、測試驗證、跨部門協調與責任追蹤過程中，它記錄了組織逐步累積的知識資產。Walsh 與 Ungson[5]提出組織記憶（organizational memory）概念，指出組織會在日常活動中累積資料、資訊與知識，而這些內容只有在能被保存、檢索與再利用時，才會真正支持後續決策與組織學習。依此觀點，會議記錄中的決策依據、任務指派、負責人、期限與追蹤結果，皆屬於組織記憶的重要內容。

Alavi 與 Leidner[6]從知識管理系統角度補充，知識管理並非單純儲存知識，而是涵蓋知識建立、組織、傳遞與應用。若企業文件只是以 PDF 或一般檔案形式被動保存，卻缺乏結構化儲存、檢索與關聯分析能力，文件中的知識便難以回到日常工作流程中發揮作用。因此，會議記錄檢索系統的設計目標不應只是保存檔案，而應把文件轉換為可查詢、可追蹤、可連結與可回溯的知識資源。

企業搜尋（enterprise search）則提供企業內部知識再利用的技術基礎。Kruschwitz 與 Hull[7]指出，企業搜尋面對的資料來源通常橫跨文件管理系統、內部網站、電子郵件、資料庫與檔案系統，且同時包含結構化與非結構化資料。會議記錄正位於這兩者之間：它以 PDF 文件保存，卻包含會議名稱、日期、出席人員、任務項目、負責人與追蹤結果等半結構化資訊。本研究因此將會議記錄視為介於文件與資料庫之間的知識載體，並以結構化解析、欄位化檢索與圖譜關聯查詢作為知識再利用的主要方法。

2.2 會議記錄、任務追蹤與行動項目文件

相較於一般企業文件，會議記錄更具有任務導向與責任導向特徵。一般文件檢索多著重文件是否包含查詢詞；會議記錄的關鍵資訊卻常落在會議項目層級，例如會議內容、負責人、預計日期、實際完成日與追蹤結果。這些欄位共同描述「哪一項任務、由誰負責、何時完成、目前狀態如何」等管理問題，使會議記錄不同於一般長篇文本。

會議與行動項目（action items）研究也指出，會議內容常包含待執行任務與承諾事項。Purver 等人[8]針對多人對話中的行動項目進行偵測與摘要，將問題拆分為偵測行動項目相關對話片段，以及擷取能表達任務內容的摘要片語。雖然本研究處理的是已整理為固定格式 PDF 的會議記錄，而非原始語音或逐字稿，但核心需求相近：系統仍必須辨識任務、負責人與日期等結構資訊。會議記錄與一般文件檢索差異如表 2.1 所示。

因此，本研究不將任意長度的文字切塊視為唯一處理單位，而是把會議項目（MeetingItem）作為主要檢索與問答來源。此設計可保留「內容—負責人—日期—追蹤結果」之間的關係，使檢索結果不只回傳相關文件，也能支援任務追蹤、責任查詢與來源回溯。

表 2.1 會議記錄與一般文件檢索之差異

比較面向	一般文件檢索	會議記錄檢索
主要檢索單位	文件、段落或文字片段	文件、會議與會議項目
核心資訊	主題內容與關鍵詞	任務內容、負責人、日期、狀態與關鍵詞
查詢需求	找出相關文件	找出相關任務、責任人、時程與追蹤結果
結構需求	可使用全文索引或 chunk 檢索	需保留欄位與任務關係
問答需求	根據片段產生回答	需附來源、欄位與圖譜關聯路徑

2.3 文件結構解析、表格辨識與欄位抽取

企業會議記錄常以 PDF 或掃描型 PDF 保存，內容則具有固定欄位與表格結構。若系統只把整份 PDF 當作一般文字處理，會議名稱、日期、負責人與追蹤結果等欄位語意便會被稀釋。因此，文件結構解析是本研究進行欄位化檢索與知識圖譜建構之前的必要步驟。

Zanibbi、Blostein 與 Cordy[1]在表格辨識研究中指出，表格模型涉及的不僅是實體位置，也包含邏輯結構與資料關係；其辨識過程可涵蓋格模型、實體位置、邏輯結構與資料關係等要素。此觀點說明，表格資料不是單純文字集合，而是透過欄、列、標題與儲存格關係組織出的結構化資訊。對本研究而言，會議項目中的項次、會議內容、負責人、日期與追蹤結果，正是表格結構承載的核心語意。

近年文件理解研究也強調文字與版面資訊的結合。LayoutLM[2]透過同時建模文字、二維位置與影像特徵，改善表單理解、收據理解與文件分類等任務，顯示文件理解不能只依賴文字序列。PubTabNet[9]針對影像型表格辨識提出大規模資料集與結構化 HTML 表示，強調表格結構與儲存格內容需共同重建；DocLayNet[10]則提供多樣來源文件的版面標註資料集，以提升一般文件版面分析模型的泛化能力。

上述研究對本研究有兩項直接啟示。第一，版面與表格結構會影響資訊擷取與檢索品質。第二，通用文件理解模型雖能處理多樣版面，但本研究的處理對象是格式固定的企業會議記錄，因此主要貢獻不在一般版面偵測或完整表格影像重建，而在以欄位辨識與列級任務抽取支援後續檢索、任務追蹤與圖譜建構。

2.4 詞彙式檢索、BM25 與欄位化檢索

資訊檢索 (Information Retrieval, IR) 的核心任務，是根據使用者查詢，從文件集中找出相關文件並排序。Manning、Raghavan 與 Schütze[11]指出，資訊檢索系統不同於傳統資料庫查詢；使用者通常以自然語言或短關鍵字提出需求，系統則透過詞彙匹配、統計權重與排序模型回傳可能相關的結果。企業會議記錄搜尋亦具有此特性，因為使用者常以專案名稱、產品名稱、關鍵詞、人名或任務片語作為查詢。

BM25 是詞彙式檢索中常用且具有代表性的排序模型。Robertson 與 Zaragoza[12] 整理 probabilistic relevance framework 與 BM25，說明其透過詞頻、逆文件頻率與文件長度正規化，估計文件與查詢之間的相關程度。BM25 的優點在於可解釋、效率高，且不需大量標註資料，因此適合作為企業文件檢索的基準方法。

不過，固定格式會議記錄不是單一欄位文件。同一查詢詞出現在會議名稱、會議內容、負責人、權責單位或追蹤結果中，語意強度與使用者意圖可能不同。BM25F 與多欄位檢索研究正是針對此問題延伸而來。Pérez-Iglesias 等人[13]將 BM25/BM25F 整合至 Lucene，說明不同文件欄位可設定不同權重；Zamani 等人[14]則探討多欄位文件的神經排序模型，指出文件中不同欄位對排序結果具有不同貢獻。

本研究參考 BM25 與 BM25F 的精神，將會議記錄視為多欄位文件，並保留查詢詞命中的欄位資訊。相較於只回傳文件分數的全文檢索，本研究的結構感知檢索會同時輸出 `matched_fields`、`snippet` 與 `score_detail`，使使用者能理解結果為何被排序在前。例如，查詢詞命中 `meeting_name` 時代表主題層級相關；命中 `content` 時多指向任務或決策內容；命中 `owner` 則偏向責任歸屬查詢。此設計把欄位化檢索由排序機制延伸為可解釋檢索與圖譜展開的基礎。

2.5 檢索粒度、向量檢索與混合式檢索

檢索單位會直接影響排序結果、回答品質與來源回溯能力。傳統文件檢索多以整份文件為單位；開放領域問答與 RAG 系統則常將文件切分為 `chunk` 後再進行檢索。Karpukhin 等人[15]提出 Dense Passage Retrieval (DPR)，以雙編碼器將問題與段落映射至連續向量空間，再以內積相似度進行檢索，證明稠密向量能捕捉同義詞、改寫與語意相近但字面不同的查詢需求。

然而，固定長度 `chunk` 不一定適合會議記錄。若系統任意切分文件，會議內容、負責人、預計日期與追蹤結果可能被切到不同片段，導致任務關係斷裂；若以整份文件為單位，又會因粒度過粗而難以定位具體任務與欄位命中位置。基於此，本研究以會議項目作為主要檢索單位，並保留其所屬會議與文件來源，使系統同時支援項目層級排序、文件層級彙整與來源回溯。

混合式檢索可結合詞彙式檢索與語意向量檢索的優點。詞彙式檢索適合處理專有名詞、代碼、日期、人名與精確欄位條件；向量檢索則較能處理語意相近但字面不同的表述。Xu 等人[16]在 TREC Deep Learning Track 的混合式檢索與多階段排序研究中指出，實務檢索系統常透過 `sparse retrieval`、`dense retrieval` 與 `reranking` 等階段提升召回與排序品質。對本研究而言，結構感知檢索提供精確欄位命中與初步排序，向量檢索補充語意召回，兩者共同支援 GraphRAG 問答上下文的建構。

2.6 查詢擴展與圖譜輔助查詢擴展

使用者查詢通常較短，也可能與文件實際用詞不一致，因此查詢擴展 (Query Expansion, QE) 長期是資訊檢索的重要研究方向。Azad 與 Deepak[3]將查詢擴展定義

為透過新增有意義詞彙來重構使用者原始查詢，以提升檢索效果，並指出擴展詞可來自文件集合、外部知識資源、搜尋記錄或混合來源。Rocchio[17]提出的 relevance feedback 是早期代表方法，其核心精神是利用初步檢索結果與使用者回饋調整查詢向量；Xu 與 Croft[18]則說明可透過 local and global document analysis 產生擴展詞。

傳統查詢擴展多聚焦詞彙相似或共現關係，較少處理文件之間的結構性關聯。Xia 等人[4]提出 Knowledge-Aware Query Expansion，指出既有 LLM-based query expansion 多強化查詢與文件的文本相似度，卻可能忽略文件間的結構關係；該研究透過知識圖譜中的文件關係，支援同時具有文本需求與關係需求的半結構化檢索。

本研究的圖譜輔助查詢擴展即建立在此觀點上。使用者可能只輸入一個關鍵詞，但實際需求往往涉及與該詞共現的任務、負責人、日期或其他會議項目。因此，系統在初步結構感知檢索後，會進一步依據關鍵字命中欄位與會議記錄知識圖譜，展開相關關鍵詞與關聯路徑。

2.7 可解釋檢索與來源可追溯性

企業檢索系統不只要回傳相關結果，也需要交代結果為何相關。可解釋資訊檢索（Explainable Information Retrieval）研究關注檢索模型如何提供可理解的排序依據、特徵貢獻與結果說明。Anand 等人[19]指出，可解釋檢索可提升使用者對結果的理解與信任；在專業或高風險決策場域中，使用者通常更需要知道系統排序的依據。

在會議記錄檢索情境中，可解釋性尤其重要。若系統只顯示「文件 A 與查詢相關」，使用者仍得自行打開文件確認關鍵字位置、涉及任務與責任人。相對地，若系統能提供 matched_fields、命中片段、欄位分數與圖譜關聯路徑，使用者便能更快判斷結果是否符合需求。此設計也支援後續 GraphRAG 問答，因為生成式回答除了自然語言結論，還應附帶會議名稱、項次、欄位來源與圖譜路徑，使答案可被驗證與回溯。

2.8 知識圖譜與關聯查詢

知識圖譜（Knowledge Graph, KG）是一種以圖形結構組織的結構化語意知識庫，主要由實體（Entity）與關係（Relation）組成，基本單位可表示為實體—關係—實體三元組；節點表示實體，邊表示實體之間的關係，如圖 2.1 所示。Hogan 等人[20]指出，知識圖譜可用於整合、管理與查詢多來源資料，並能透過圖查詢語言支援路徑搜尋、關聯探索與結構化查詢。與關聯式資料表相比，圖資料模型更適合表示多對多與多跳關係。

Nickel 等人[21]從 relational machine learning 與知識圖譜角度指出，知識圖譜能將事實表示為實體與關係，並支援關係推論、未知關係預測等任務。不過，本研究使用知識圖譜的目的並不是進行大規模關係推論或知識補全，而是把會議記錄中已明確存在的欄位關係轉換為可查詢的圖結構。

因此，本研究將知識圖譜定位為「關聯查詢層」。原始結構化事實仍可保存於文件

資料庫；知識圖譜則用於表示 Document、Meeting、MeetingItem、Person、Unit、Date 與 Keyword 等節點，以及 HAS_MEETING、HAS_ITEM、RESPONSIBLE_BY、HAS_PLANNED_DATE、MENTIONS 與 CO_OCCURS_WITH 等關係。透過此設計，系統可從文件、會議項目、人員、日期或關鍵詞出發，進行一階或二階關聯展開，支援使用者由檢索結果進一步探索任務脈絡。




圖 2.1 知識圖譜組成示例圖

資料來源：維基百科

2.9 RAG 與 GraphRAG

Retrieval-Augmented Generation (RAG) 將外部知識檢索結果納入語言模型輸入，其核心流程可概括為檢索 (Retrieval)、增強 (Augmentation) 與生成 (Generation)，目的在於讓生成模型能引用可更新且可檢視的來源。Lewis 等人[22]提出 RAG 模型，結合預訓練 seq2seq 模型與 dense vector index，將 parametric memory 與 non-parametric memory 互補使用於 knowledge-intensive NLP tasks。該研究指出，外部記憶有助於改善語言模型的知識更新、來源檢視與事實性問題。

Gao 等人[23]將 RAG 發展歸納為 Naive RAG、Advanced RAG 與 Modular RAG，並指出典型 RAG 系統包含 indexing、retrieval 與 generation 三階段；進階架構則會在 retrieval 前後加入查詢改寫、檢索優化、reranking、metadata 與多模組流程。本研究架構更接近 Modular RAG，因為它整合結構化檢索、知識圖譜關聯展開、向量檢索與語言模型回答生成，而不是單純以向量相似度回傳 top-k chunk。

GraphRAG 則進一步把圖結構納入 RAG 流程。Edge 等人[24]提出 GraphRAG，先由來源文件建立 entity knowledge graph，再透過圖社群摘要支援全域 query-focused summarization；該方法主要處理 global sensemaking 問題，例如詢問整個語料庫的主要主題或趨勢。Zhang 等人[25]的 GraphRAG survey 則將 GraphRAG 區分為 knowledge-based、index-based 與 hybrid 類型，並指出圖結構可支援多跳推理、結構化知識整合與 context-preserving retrieval。

本研究與上述 GraphRAG 研究相關，但問題設定有所不同。本研究不以全語料社群摘要為主要方法，而是利用固定格式會議記錄中的欄位與任務關係建立領域知識圖譜，並在使用者選擇檢索結果後展開文件、會議項目、人員、日期與關鍵詞脈絡。就定位而言，本研究較接近 domain-specific structured KG、item-level retrieval 與 source-grounded GraphRAG 的結合；其重點是讓會議記錄問答能回溯到具體會議項目與欄位，而不是只生成整體語料摘要。

2.10 檢索、關聯展開與 GraphRAG 評估方法

為驗證本研究方法的有效性，需要同時考量檢索、欄位命中、圖譜展開與問答結果。資訊檢索通常以 Precision@K、Recall@K、Mean Reciprocal Rank (MRR) 與 Normalized Discounted Cumulative Gain (NDCG) 等指標評估排序品質[11]。對會議記錄檢索而言，若檢索單位為 MeetingItem，便可由人工標註相關項目作為 ground truth，檢查系統是否能在 top-k 結果中找出真正相關的會議項目。

排序品質之外，本研究也關注欄位命中與圖譜關聯展開。欄位命中可透過 Field Match Accuracy 或 matched field correctness 評估，也就是檢查系統判斷查詢詞所在欄位是否正確。圖譜關聯展開則可透過 Relation Precision@K 或 Path Correctness 評估，確認展開的人員、日期、關鍵詞與會議項目是否與原始資料相符。

GraphRAG 問答評估需同時看回答內容與來源依據。Gao 等人[23]在 RAG survey 中整理檢索品質、生成品質與回答品質等面向；Edge 等人[24]在 GraphRAG 評估中採用 LLM-as-a-judge，比較回答的 comprehensiveness、diversity 與 empowerment。就本研究而言，除了完整性與相關性，更關鍵的是回答是否忠於檢索來源、是否能附帶正確來源位置與關聯關係，以及是否避免生成未被會議記錄支持的內容。表 2.2 彙整本研究對應之評估面向。

表2.2 本研究對應之評估面向

評估對象	可採用指標	評估目的
結構感知檢索	Precision@K、MRR、NDCG	比較一般關鍵字檢索、BM25、結構感知檢索與向量檢索之排序品質
欄位命中	Field Match Accuracy、matched field correctness	確認系統是否正確記錄查詢詞命中的欄位
圖譜關聯展開	Relation Precision@K、Path Correctness	確認展開的人員、任務、日期與關鍵詞是否正確
GraphRAG 問答	Faithfulness、Answer Relevance、Source Accuracy、Citation Correctness	確認回答是否完整、相關、具來源依據且可回溯

第三章 研究方法

3.1 研究架構

本研究提出結構感知檢索、知識圖譜關聯展開與 GraphRAG 問答三層式架構。第一層為結構感知檢索層，負責將使用者查詢與會議記錄欄位逐項比對，並輸出排序分數、命中欄位與摘要片段。第二層為知識圖譜關聯展開層，將使用者選擇的文件或會議項目作為查詢起點，展開其與人員、單位、日期及關鍵詞之間的關係。第三層為 GraphRAG 問答層，整合結構化檢索結果、圖譜路徑與語意相似內容，產生可回溯來源的自然語言回答。整體系統流程如圖 3.1 所示。

此架構的設計判斷是：檢索結果不應只是文件清單，而應成為後續知識探索與問答生成的入口。傳統關鍵字檢索能提供初步相關文件，卻難以表達文件內部的任務、人員與日期關係；知識圖譜能補足關係展開能力，但仍需結構化檢索提供明確入口；GraphRAG 則把檢索內容與圖譜脈絡轉換為可閱讀、可驗證的回答。




圖 3.1 系統流程圖
資料來源：本研究整理

3.2 會議記錄結構化資料模型

本研究將會議記錄劃分為文件、會議主檔與會議項目三個層次。Document 代表原始 PDF 文件；Meeting 代表文件中記載的會議主檔；MeetingItem 則代表會議表格中的單一議題、任務或追蹤項目。三者形成 Document -> Meeting -> MeetingItem 的層級關係。會議主檔資料模型如表 3.1 所示，會議項目資料模型如表 3.2 所示。

本研究以 MeetingItem 作為主要檢索與問答來源單位。主要原因在於，會議記錄中最具管理價值的內容，例如任務內容、負責人、預計日期、實際完成日與追蹤結果，皆集中於會議項目層級。若以整份文件作為檢索單位，粒度過粗，使用者仍需自行閱讀文件才能找到任務；若採任意文字 chunk，則可能切斷「內容、負責人、日期、追蹤結果」之間的欄位關係。因此，本研究採會議項目作為基本檢索單位，再以文件層級結果作為介面中的彙整入口。

文件層級排序結果由同一文件下多筆 MeetingItem 分數彙整而得。透過此設計，系統可同時支援項目層級精準檢索與文件層級瀏覽。當使用者查詢具體任務、負責人或日期時，系統能直接呈現相關 MeetingItem；若使用者需要閱讀完整會議內容，則可透過 document_id 回到原始文件。

表 3.1 會議主檔資料模型

欄位	說明	用途
meeting_id	會議識別碼	連結會議項目與圖譜節點
document_id	所屬文件識別碼	回溯原始 PDF 文件
meeting_name	會議名稱或主題	主題檢索與文件排序
meeting_date	會議日期	日期查詢與時間篩選
location	會議地點	地點條件查詢
chairperson	主席	人員關係展開
recorder	記錄人	人員關係展開
responsible_unit	權責單位	單位查詢與責任歸屬
attendees	出席人員	參與關係與人員探索

表 3.2 會議項目資料模型

欄位	說明	用途
item_id	會議項目識別碼	主要檢索、問答與來源回溯單位
meeting_id	所屬會議識別碼	連結至會議主檔
item_no	項次或序號	呈現原始會議項目位置
content	會議內容、決議或待辦事項	任務與議題檢索
owner	負責人	責任歸屬與人員查詢
planned_date	預計完成日期	時程追蹤與日期條件查詢
actual_completed_date	實際完成日期	完成狀態判斷
tracking_result	追蹤結果或處理狀態	任務狀態與結果查詢

3.3 會議記錄結構化解析方法

本研究處理對象為固定格式且可取得文字層內容的會議記錄 PDF。解析方法並不以通用文件版面理解或掃描影像辨識作為主要目標，而是利用會議記錄格式穩定的特性，將文件解析為會議主檔與會議項目兩層資料。

對會議主檔而言，系統依欄位名稱、相對位置與文字格式擷取會議名稱、日期、地點、主席、記錄人、權責單位與出席人員。對會議項目表格而言，系統依項次、欄位順序與列邊界進行 row-level extraction，將每列對應至 content、owner、planned_date、actual_completed_date 與 tracking_result 等欄位。結構化解析流程如圖 3.2 所示。此方法呼應表格辨識研究中 physical structure 與 logical structure 的區分[1]，但本研究目標不是完整重建 HTML 表格，而是擷取足以支援檢索、任務追蹤與圖譜建構的欄位資料。




圖 3.2 結構化解析流程

3.4 結構感知檢索模型

結構感知檢索模型的目的，是在傳統詞彙相關度之外，保留查詢詞命中的欄位語意，並將欄位、任務狀態與圖譜擴展資訊納入排序。與一般全文檢索不同，本研究不只判斷查詢詞是否出現，也記錄其出現於 meeting_name、content、owner、responsible_unit、attendees 或 tracking_result 等欄位。

3.4.1 檢索單位與欄位集合

令 q 表示使用者查詢， i 表示一筆 MeetingItem， d 表示一份 Document。
MeetingItem i 的欄位集合定義為 $F = \{\text{meeting_name}, \text{content}, \text{owner}, \text{responsible_unit}, \text{attendees}, \text{tracking_result}, \text{planned_date}, \text{actual_completed_date}\}$ 。其中，meeting_name 與 responsible_unit 來自所屬 Meeting；content、owner、planned_date、actual_completed_date 與 tracking_result 則來自 MeetingItem 本身。

系統會對每一筆 MeetingItem 逐欄位計算命中狀態，並保留命中欄位資訊。這使檢索結果能產生 matched_fields 與 score_detail，讓使用者判斷結果為何被視為相關。檢索欄位與語意功能如表 3.4 所示。

表 3.4 檢索欄位與語意功能

欄位	語意意義	檢索與解釋用途
meeting_name	會議主題命中	代表查詢與會議主題高度相關
content	任務、決議或討論內容命中	代表查詢與具體會議項目相關
owner	任務負責人命中	支援人員與責任歸屬查詢
responsible_unit	權責單位命中	支援部門或單位查詢
attendees	出席人員命中	代表參與關係，但不一定代表負責關係
tracking_result	追蹤結果命中	支援狀態、結果與完成情形查詢
planned_date / actual_completed_date	日期條件命中	支援時程、逾期與完成日查詢

欄位命中資料可表示如下。此資料結構並非最終系統資料庫 schema，而是用於描述欄位命中與結果解釋的抽象格式。

```

{
  "keyword": "關鍵字A",
  "collection": "meeting_items",
  "field": "content",
  "document_id": "doc_xxx",
  "meeting_id": "meet_xxx",
  "item_id": "item_xxx",
  "match_type": "exact",
  "snippet": "...關鍵字A..."
}

```

3.4.2 項目層級排序分數

本研究以項目層級分數 $\text{Score_item}(i, q)$ 作為主要排序依據。分數由詞彙相關度、欄位命中、結構重要性、任務狀態與圖譜擴展等項目組成。為避免不同分數尺度直接相加造成偏誤，各分數項需先正規化至 0 到 1 區間，再依權重加總。

$$\text{Score_item}(i, q) = w_{\text{lex}} S_{\text{lex}}(i, q) + w_{\text{field}} S_{\text{field}}(i, q) + w_{\text{struct}} S_{\text{struct}}(i, q) + w_{\text{task}} S_{\text{task}}(i, q) + w_{\text{graph}} S_{\text{graph}}(i, q)$$

其中， S_{lex} 表示詞彙相關度分數，可參考 BM25 對詞頻、反向文件頻率與文件長度正規化的設計[12]； S_{field} 表示欄位命中分數； S_{struct} 表示結構重要性分數； S_{task} 表示任務狀態分數； S_{graph} 表示圖譜擴展分數。 w_{lex} 、 w_{field} 、 w_{struct} 、 w_{task} 與 w_{graph} 為各分數項權重。正式實驗階段可透過消融實驗觀察各分數項對排序品質的影響。項目層級排序分數項如表 3.5 所示。

表3.5 項目層級排序分數項

分數項	意義	啟用時機
S_{lex}	查詢詞與會議項目文字之詞彙相關度	所有查詢皆啟用
S_{field}	查詢詞命中不同欄位所產生之欄位權重	所有查詢皆啟用
S_{struct}	meeting_name、owner、responsible_unit 等高語意欄位之結構重要性	所有查詢皆啟用，但依查詢類型調整權重
S_{task}	是否涉及負責人、預計日期、完成日期或追蹤結果	查詢意圖涉及任務、狀態、期限或追蹤時啟用
S_{graph}	由知識圖譜關聯詞或關聯路徑導入之擴展分數	進行圖譜擴展或二階檢索時啟用

S_{field} 可定義為查詢詞在各欄位命中的加權總和：

$$S_{\text{field}}(i, q) = \text{Normalize}(\sum_{f \in F} \text{field_weight}(f, q_type) * \text{match}(q, x_{i,f}))$$

其中， $x_{i,f}$ 表示項目 i 在欄位 f 中的文字， $\text{match}(q, x_{i,f})$ 表示查詢詞是否命中該欄位內容，可依 exact match、partial match 或 synonym match 給予不同分數； $\text{field_weight}(f, q_type)$ 表示欄位權重，並可依查詢類型調整。

S_{task} 不應無條件提高所有未完成任務的排序，否則一般主題查詢可能被任務狀態扭曲。因此，本研究將 S_{task} 設定為條件式分數：只有當查詢涉及「未完成」、「逾期」、「預計日期」、「完成日」、「追蹤」等任務狀態意圖時，才提高具有負責人、日期或追蹤結果欄位的項目權重；若查詢只是一般主題或產品關鍵詞，則 S_{task} 權重設為 0 或維持低權重。

3.4.3 文件層級結果彙整

雖然本研究以 MeetingItem 作為主要檢索單位，使用者介面仍需呈現文件層級結果。文件層級分數由該文件底下的會議項目分數彙整而得。

$$Score_doc(d, q) = \max_{\{i \in Items(d)\}} Score_item(i, q) + \eta * AvgTopM_{\{i \in Items(d)\}} Score_item(i, q)$$

其中，Items(d) 表示文件 d 所包含的會議項目集合。max 項保留文件中最相關項目的代表性；AvgTopM 則反映文件中多個相關項目的整體關聯度， η 為文件層級彙整權重。此設計可避免單一弱相關命中讓整份文件過度靠前，也可避免多筆中高相關會議項目被單一最大值忽略。結構感知檢索流程如圖 3.3 所示。




圖3.3 結構感知檢索流程

3.5 知識圖譜建構方法

本研究將結構化會議記錄轉換為知識圖譜，以顯性表示文件、會議、會議項目、人員、單位、日期與關鍵詞之間的關係。系統知識圖譜節點屬性如表 3.6 所示，關係屬性如表 3.7 所示。此知識圖譜並非用於預測未知事實或進行大規模知識補全，而是作為關聯查詢、圖譜展開與 GraphRAG 上下文組裝的基礎。此定位符合以節點表示實體、以邊表示關係的知識圖譜基本觀點[20]。

表 3.6 系統知識圖譜節點

節點類型	來源資料	主要屬性	用途
Document	原始 PDF 文件	document_id、file_name、upload time	文件層級回溯與瀏覽
Meeting	會議主檔	meeting_id、meeting_name、meeting_date	會議主題與日期查詢
MeetingItem	會議項目	item_id、item_no、content、tracking_result	任務、決議與追蹤查詢
Person	主席、記錄人、出席者、負責人	person_id、display_name	人員責任與參與關係展開
Unit	權責單位或部門	unit_id、unit_name	單位責任與部門查詢
Date	會議日期、預計日期、完成日期	date_value、date_type	時間條件與任務時程查詢
Keyword	查詢詞、欄位關鍵詞與抽取詞彙	keyword_id、term、frequency	關鍵詞共現與查詢擴展

表 3.7 系統知識圖譜關係

關係類型	起點	終點	語意
HAS_MEETING	Document	Meeting	文件包含會議
HAS_ITEM	Meeting	MeetingItem	會議包含會議項目
CHAired_BY	Meeting	Person	會議由某人主持
RECORDED_BY	Meeting	Person	會議由某人記錄
ATTENDED_BY	Meeting	Person	人員出席會議
BELONGS_TO_UNIT	Meeting 或 MeetingItem	Unit	會議或項目屬於特定權責單位
RESPONSIBLE_BY	MeetingItem	Person	會議項目由某人負責
HAS_PLANNED_DATE	MeetingItem	Date	會議項目具有預計日期
HAS_COMPLETED_DATE	MeetingItem	Date	會議項目具有實際完成日
MENTIONS	Meeting 或 MeetingItem	Keyword	會議或項目提及關鍵詞，並保留 field 屬性
CO_OCCURS_WITH	Keyword	Keyword	關鍵詞在同一項目或同一會議中共現

MENTIONS 關係是連接結構感知檢索與知識圖譜的關鍵設計。一般關鍵詞節點只能表示「某項目提到某詞」；本研究則在 MENTIONS 關係中保留 field 屬性，使系統能表示「某詞出現在會議名稱、任務內容、負責人或追蹤結果等欄位」。透過此設計，欄位命中資訊可延續到圖譜關聯展開與 GraphRAG 上下文中。

(Document)-[:HAS_MEETING]->(Meeting)

(Meeting)-[:HAS_ITEM]->(MeetingItem)

(MeetingItem)-[:RESPONSIBLE_BY]->(Person)

(MeetingItem)-[:HAS_PLANNED_DATE]->(Date)

(MeetingItem)-[:MENTIONS {field: "content"}]->(Keyword)

(Keyword)-[:CO_OCCURS_WITH {weight: 0.72}]->(Keyword)

Keyword 節點來源包括三類。第一類為使用者查詢詞，系統可將查詢詞與命中欄位關聯到既有或新建的 Keyword 節點。第二類為會議項目內容經斷詞、停用詞過濾與頻率門檻篩選後產生的候選詞。第三類為研究者依會議記錄領域整理的領域詞表，例如任務狀態、文件類型、產品類型或作業流程代稱。為避免低品質詞彙造成圖譜雜訊，系統僅保留達到最低出現次數、出現在重要欄位或屬於指定領域詞表的詞彙。

CO_OCCURS_WITH 關係用於表示關鍵詞之間的共現脈絡。若兩個 Keyword 節點共同出現在同一 MeetingItem 中，系統會建立或更新共現關係；若兩詞出現在同一 Meeting 但不同 MeetingItem 中，則可建立較低權重的共現關係。關係權重可依共現次數、詞頻與圖譜距離進行正規化。

$$\text{Rel}(k_a, k_b) = \text{cooccur}(k_a, k_b) / \sqrt{\text{freq}(k_a) * \text{freq}(k_b)}$$

上述公式表示兩個關鍵詞的正規化共現強度，其中 $\text{cooccur}(k_a, k_b)$ 為兩詞共同出現次數， $\text{freq}(k_a)$ 與 $\text{freq}(k_b)$ 為各詞出現次數。此權重可供後續圖譜輔助查詢擴展與排序加權使用。

3.6 圖譜關聯展開與圖譜輔助查詢擴展

本研究的圖譜關聯展開以使用者點擊檢索結果作為起點。當使用者輸入查詢並取得初步排序結果後，系統不會直接把整個知識圖譜送入生成模型，而是先根據使用者選擇的 document_id、meeting_id、item_id 或 keyword 定位圖譜起點，再限制展開範圍與路徑長度，以取得與使用者意圖較相關的關係。

圖譜關聯展開包含三類主要路徑。第一類為文件到任務路徑，即 Document -> Meeting -> MeetingItem，用於呈現文件內部有哪些會議項目。第二類為任務到責任路徑，即 MeetingItem -> Person、Unit、Date，用於呈現任務由誰負責、屬於哪個單位與何時完成。第三類為任務到關鍵詞路徑，即 MeetingItem -> Keyword -> Keyword，用於呈現任務中提及哪些關鍵詞，以及這些關鍵詞與其他詞彙的共現關係。圖譜關聯展開方式如表 3.8 所示。

表3.8 圖譜關聯展開方式

使用者行為	圖譜起點	主要展開關係	輸出內容
展開文件結果	Document	HAS_MEETING、 HAS_ITEM、MENTIONS	文件內會議、會議 項目與相關關鍵詞
展開會議項目	MeetingItem	RESPONSIBLE_BY、 HAS_PLANNED_DATE、 HAS_COMPLETED_DATE、 MENTIONS	負責人、日期、追 蹤結果與任務脈絡
展開人員或單位	Person 或 Unit	RESPONSIBLE_BY、 BELONGS_TO_UNIT	該人員或單位相關 任務
展開關鍵詞	Keyword	MENTIONS、 CO_OCCURS_WITH	相關會議項目與共 現詞
提出自然語言問題	Question- derived entities	依查詢實體與欄位命中展 開	GraphRAG 上下文 與來源路徑

為避免圖譜展開引入過多雜訊，本研究設定下列五項限制：

- 一、 預設只展開一階與二階關係；
- 二、 二階關係採用距離衰減因子；
- 三、 擴展詞數量設上限；
- 四、 關係權重低於門檻者不納入；
- 五、 不同關係類型給予不同權重，例如 RESPONSIBLE_BY 與 HAS_PLANNED_DATE 對任務追蹤問題較重要，CO_OCCURS_WITH 對主題擴展問題較重要。

圖譜輔助查詢擴展用於召回未直接包含原查詢詞，但在會議記錄業務脈絡中高度相關的項目。此設計延伸一般查詢擴展降低 vocabulary mismatch 的目的[3]，並進一步處理會議記錄中的 relation mismatch。Xia 等人提出的 Knowledge-Aware Query Expansion 顯示，半結構化檢索任務往往同時包含文本需求與關係需求，因此查詢擴展不應只依賴語意相似詞，也應納入知識圖譜中的結構關係[4]。

$$S_{\text{graph}}(i, q) = \sum_{\{k \in \text{Expand}(q)\}} S_{\text{field}}(i, k) * \text{Rel}(q, k) * \text{Decay}(\text{dist}(q, k))$$

其中，Expand(q) 表示由知識圖譜取得的擴展詞集合，S_field(i, k) 表示擴展詞 k 在項目 i 中的欄位命中分數，Rel(q, k) 表示查詢詞與擴展詞的關係權重，dist(q, k) 表示圖譜距離，Decay(dist(q, k)) 則表示距離衰減因子。預設一階關係衰減值為 1，二階關係衰減值小於 1，超過二階者不納入主要排序。圖譜關聯展開與查詢擴展流程如圖 3.4 所示。




圖 3.4 圖譜關聯展開與查詢擴展流程

3.7 GraphRAG 問答方法

本研究的 GraphRAG 問答方法屬於領域導向 GraphRAG。不同於以整個語料庫建立社群摘要並回答全域 sensemaking 問題的 GraphRAG 方法[24]，本研究聚焦於固定格式會議記錄，採會議項目層級檢索與圖譜關聯路徑組裝上下文，使回答能對應至明確的會議項目、負責人、日期與來源文件。

GraphRAG 問答流程整合三類上下文。第一類為 Structured Context，包含 meeting_name、meeting_date、item_no、content、owner、planned_date、actual_completed_date 與 tracking_result。第二類為 Graph Context，包含從知識圖譜取得的人員、單位、日期、關鍵詞與 graph paths。第三類為 Semantic Context，包含向量檢索召回的語意相近會議項目。GraphRAG 上下文類型如表 3.9 所示。RAG 研究指出，生成模型結合可檢索之外部記憶可改善知識密集型任務並提供可檢查來源[22]；本研究進一步要求回答附帶 MeetingItem 來源與圖譜路徑，以強化可追溯性。

表3.9 GraphRAG 上下文組成

上下文類型	內容	主要用途
Structured Context	meeting_name、meeting_date、item_no、content、owner、planned_date、actual_completed_date、tracking_result	提供回答所需的結構化事實與原始欄位資訊
Graph Context	Document、Meeting、MeetingItem、Person、Unit、Date、Keyword 及 graph paths	提供任務、人員、日期與關鍵詞之關聯脈絡
Semantic Context	向量檢索召回之語意相近 MeetingItem 與摘要片段	補充同義詞、改寫查詢或未直接命中關鍵字的相關內容
Source Metadata	document_id、meeting_id、item_id、item_no、file_name	支援回答來源回溯與人工驗證

GraphRAG 上下文組裝時，系統需避免把過多資料直接放入提示詞。流程上，先由結構感知檢索取得 Top-K MeetingItem；接著針對使用者點擊結果或查詢實體展開 Top-P graph paths；再由向量檢索補充 Top-M 語意相近項目。最後，系統依分數、路徑長度與來源多樣性組裝上下文。GraphRAG 上下文組裝與回答生成流程如圖 3.5 所示。




圖 3.5 GraphRAG 上下文組裝與回答生成流程

```

{
  "answer": "根據現有會議記錄，關鍵字A主要涉及項目03與項目07，負責人為人員A，預計完成日期為YYYY-MM-DD。",
  "sources": [
    {
      "document_id": "doc_xxx",
      "meeting_id": "meet_xxx",
      "meeting_name": "專案A階段審查會議",
      "meeting_date": "YYYY-MM-DD",
      "item_id": "item_xxx",
      "item_no": "03"
    }
  ],
  "graph_paths": [
    "(MeetingItem:item_xxx)-[:RESPONSIBLE_BY]->(Person:人員A)",
    "(MeetingItem:item_xxx)-[:HAS_PLANNED_DATE]->(Date:YYYY-MM-DD)",
    "(MeetingItem:item_xxx)-[:MENTIONS {field: content}]->(Keyword:關鍵字A)"
  ]
}

```

為提高回答可信度，本研究設定三項生成限制。第一，語言模型不得使用未出現在檢索結果、圖譜路徑或語意上下文中的事實。第二，若不同來源之間存在衝突，回答需標明來源差異，而不是自行合併為單一結論。第三，若現有資料不足以回答問題，系統應回覆「無法由現有會議記錄確認」，避免生成未被來源支持的內容。

參考文獻

- [1] Zanibbi, R., Blostein, D., & Cordy, J. R. (2004). A survey of table recognition: Models, observations, transformations, and inferences. *International Journal on Document Analysis and Recognition*, 7, 1–16. <https://doi.org/10.1007/s10032-004-0120-9>
- [2] Xu, Y., Li, M., Cui, L., Huang, S., Wei, F., & Zhou, M. (2020). LayoutLM: Pre-training of text and layout for document image understanding. *Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, 1192–1200. <https://doi.org/10.1145/3394486.3403172>
- [3] Azad, H. K., & Deepak, A. (2019). Query expansion techniques for information retrieval: A survey. *Information Processing & Management*, 56(5), 1698–1735. <https://doi.org/10.1016/j.ipm.2019.05.009>
- [4] Xia, Y., Wu, J., Kim, S., Yu, T., Rossi, R. A., Wang, H., & McAuley, J. (2025). Knowledge-aware query expansion with large language models for textual and relational retrieval. *arXiv*. <https://arxiv.org/abs/2410.13765>
- [5] Walsh, J. P., & Ungson, G. R. (1991). Organizational memory. *Academy of Management Review*, 16(1), 57–91. <https://doi.org/10.5465/amr.1991.4278992>
- [6] Alavi, M., & Leidner, D. E. (2001). Review: Knowledge management and knowledge management systems: Conceptual foundations and research issues. *MIS Quarterly*, 25(1), 107–136. <https://doi.org/10.2307/3250961>
- [7] Kruschwitz, U., & Hull, C. (2017). Searching the enterprise. *Foundations and Trends in Information Retrieval*, 11(1), 1–142. <https://doi.org/10.1561/15000000053>
- [8] Purver, M., Dowding, J., Niekrasz, J., Ehlen, P., Noorbaloochi, S., & Peters, S. (2007). Detecting and summarizing action items in multi-party dialogue. *Proceedings of the 8th SIGdial Workshop on Discourse and Dialogue*, 18–25. <https://doi.org/10.18653/v1/2007.sigdial-1.4>
- [9] Zhong, X., ShafieiBavani, E., & Jimeno Yepes, A. (2020). Image-based table recognition: Data, model, and evaluation. *arXiv*. <https://arxiv.org/abs/1911.10683>
- [10] Pfiztmann, B., Auer, C., Dolfi, M., Nassar, A. S., & Staar, P. W. J. (2022). DocLayNet: A large human-annotated dataset for document-layout analysis. *Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, 3743–3751. <https://doi.org/10.1145/3534678.3539043>
- [11] Manning, C. D., Raghavan, P., & Schütze, H. (2008). *Introduction to information retrieval*. Cambridge University Press.
- [12] Robertson, S., & Zaragoza, H. (2009). The probabilistic relevance framework: BM25 and beyond. *Foundations and Trends in Information Retrieval*, 3(4), 333–389. <https://doi.org/10.1561/15000000019>
- [13] Pérez-Iglesias, J., Pérez-Agüera, J. R., Fresno, V., & Feinstein, Y. Z. (2009). Integrating

the probabilistic models BM25/BM25F into Lucene. arXiv.
<https://arxiv.org/abs/0911.5046>

- [14] Zamani, H., Mitra, B., Song, X., Craswell, N., & Tiwary, S. (2018). Neural ranking models with multiple document fields. *Proceedings of the Eleventh ACM International Conference on Web Search and Data Mining*, 700–708.
<https://doi.org/10.1145/3159652.3159730>
- [15] Karpukhin, V., Oguz, B., Min, S., Lewis, P., Wu, L., Edunov, S., Chen, D., & Yih, W.-T. (2020). Dense passage retrieval for open-domain question answering. *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing*, 6769–6781.
<https://doi.org/10.18653/v1/2020.emnlp-main.550>
- [16] Xu, G., Zhang, Y., Zhang, L., Long, D., Xie, P., & Guo, R. (2023). Hybrid retrieval and multi-stage text ranking solution at TREC 2022 Deep Learning Track. arXiv.
<https://arxiv.org/abs/2308.12039>
- [17] Rocchio, J. J. (1971). Relevance feedback in information retrieval. In G. Salton (Ed.), *The SMART Retrieval System: Experiments in Automatic Document Processing* (pp. 313–323). Prentice-Hall.
- [18] Xu, J., & Croft, W. B. (1996). Query expansion using local and global document analysis. *Proceedings of the 19th Annual International ACM SIGIR Conference on Research and Development in Information Retrieval*, 4–11.
- [19] Anand, A., Lyu, L., Idahl, M., Wang, Y., Wallat, J., & Zhang, Z. (2022). Explainable information retrieval: A survey. arXiv. <https://arxiv.org/abs/2211.02405>
- [20] Hogan, A., Blomqvist, E., Cochez, M., D’Amato, C., de Melo, G., Gutierrez, C., Labra Gayo, J. E., Kirrane, S., Neumaier, S., Polleres, A., Navigli, R., Ngonga Ngomo, A.-C., Rashid, S. M., Rula, A., Schmelzeisen, L., Sequeda, J., Staab, S., & Zimmermann, A. (2021). Knowledge graphs. *ACM Computing Surveys*, 54(4), Article 71.
<https://doi.org/10.1145/3447772>
- [21] Nickel, M., Murphy, K., Tresp, V., & Gabrilovich, E. (2016). A review of relational machine learning for knowledge graphs. *Proceedings of the IEEE*, 104(1), 11–33.
<https://doi.org/10.1109/JPROC.2015.2483592>
- [22] Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W.-T., Rocktäschel, T., Riedel, S., & Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. *Advances in Neural Information Processing Systems*, 33, 9459–9474.
- [23] Gao, Y., Xiong, Y., Gao, X., Jia, K., Pan, J., Bi, Y., Dai, Y., Sun, J., Wang, M., & Wang, H. (2024). Retrieval-augmented generation for large language models: A survey. arXiv.
<https://arxiv.org/abs/2312.10997>
- [24] Edge, D., Trinh, H., Cheng, N., Bradley, J., Chao, A., Mody, A., Truitt, S., Metropolitansky, D., Ness, R. O., & Larson, J. (2025). From local to global: A GraphRAG

approach to query-focused summarization. arXiv. <https://arxiv.org/abs/2404.16130>

- [25] Zhang, Q., Chen, S., Bei, Y., Yuan, Z., Zhou, H., Hong, Z., Chen, H., Xiao, Y., Zhou, C., Dong, J., Chang, Y., & Huang, X. (2025). A survey of graph retrieval-augmented generation for customized large language models. arXiv. <https://arxiv.org/abs/2501.13958>

國立虎尾科技大學



National Formosa University